

# 測試大型語言模型辨識地理圖資能力

孫翊維 張子修 吳欣璉 黃于哲  
自然語言處理 期末專案書面報告

**摘要** 本研究旨在探索大型語言模型(LLM)理解與辨識航空攝影正射影像（簡稱航測影像）及數值地形圖的能力。航空攝影正射影像具備豐富的時間序列特徵，是都市變遷規劃的重要依據，但由於其垂直視角與多為公務付費資料之特性，極少被用作 LLM 的訓練數據。我們開發了一套基於 LangChain 的自動化圖資查詢平台，整合臺北市歷史圖資展示系統之 WMTS 服務，並使用 Gemini API 進行一系列對話實驗。實驗透過階層式提示詞，測試模型在單純視覺判讀、加入不同年份航測影像交叉比對，以及結合數值地形圖後，對特定地點與拍攝年份判斷的準確度提升效果。

## 1. 研究動機與問題

航空攝影正射影像(Orthophoto)係利用航空攝影測量技術製作，經正射糾正與坐標定位後之影像圖，其記錄了地形地貌隨時間變動的歷程，為都市發展與變遷分析之重要參據。然而，此類影像品質易受拍攝技術與天候影響，且多屬公務或付費資產，少見於公開之大型模型預訓練語料庫中。因此，精確辨識航測影像對於人類與機器皆具高度挑戰性。

本研究聚焦於以下核心問題：

- 探索多模態大型語言模型(LLM)理解垂直視角航測影像之內在機制。
- 測試 LLM 在無外部文本脈絡下，單憑視覺特徵判斷航測地點與拍攝年份之能力。
- 實驗透過工具調用(Agent)與階層式空間特徵比對，能否有效提升模型之判讀精準度。
- 評估不同性質圖資（航測影像 vs. 數值地形圖）對模型推理表現之影響。

## 2. 文獻回顧

近年關於 LLM 空間認知能力的研究顯示，模型在處理複雜地理圖資時仍存在限制。(O'Sullivan & others, 2024) 指出，LLM 對於距離（如「遠」與「近」）之空間概念，僅停留在靜態的字面定義，缺乏動態實際計算能力。

在視覺與城市地景判讀方面，(Zhou & others, 2024) 評估模型判讀多視角城市場景之表現，發現

LLM 在垂直視角影像（如衛星、航測影像）之表現顯著遜於街景圖，其中又以城市檢索（地點判定）之表現最為薄弱。(Dorobantu & others, 2026) 彙整相關研究後進一步證實，LLM 在回答空間任務時多基於訓練數據中的詞彙定義，於精確的幾何計算（如面積、距離及座標轉換）中表現欠佳。本研究以此為基礎，嘗試透過 Agent 機制與多時序圖資融合來克服上述限制。

## 3. 系統架構與圖資獲取

為驗證模型能力，我們實作了一套自動化圖資查詢與分析平台。

### 3.1 圖資來源與規格

本研究之數據源自「臺北市政府都市發展局歷史圖資展示系統」，涵蓋臺北市範圍內歷年（1945–2025 年）之航測影像及數值地形圖。系統提供符合網際網路地圖圖磚服務(WMTS)標準之介接服務。本系統設定擷取參數為：縮放層級(Zoom Level)16，比例尺約為 1:8500，每塊地圖圖磚(Tile)尺寸為 256 × 256 像素，單一圖磚涵蓋實際地表面積約 500 × 500 公尺。

### 3.2 圖資獲取工具設計

圖資 Agent 整合了以下核心功能模組：

- 地址解析 (Geocoding)：優先採納使用者傳入之座標；若僅輸入地名（如“台北車站”），則啟

- 座標轉換：將取得之經緯度傳入 `latlon_to_tile_xy` 函式，換算為對應之  $x$  與  $y$  圖磚索引值。
- 年份搜尋演算法：因特定地點並非每年皆有完整的航測影像，系統設計自動搜尋機制，動態抓取目標年份前後各三年的現存圖資，並透過網址比對後完成圖片下載。

本研究於 Colab (Python3 CPU) 環境下實作，測試模型採用 gemini-3.1-flash-lite，並以 Gradio 建構前端對話介面進行互動實驗。

名單如下：

1. 國父紀念館
2. 台北市政府
3. 南港展覽館
4. 達賢圖書館
5. 美麗華購物中心
6. 動物園
7. 25.09975839176, 121.51027369166 (北士科)
8. 華碩集團總部 (關渡)
9. 小巨蛋
10. 故宮
11. 政治大學自強十舍
12. 松山文創園區
13. 京華城
14. 臺北市北投老人服務中心
15. 中研院
16. 台北流行音樂中心
17. 台北車站
18. 臺北霞海城隍廟 (迪化街)
19. 捷運西門站
20. 25.1110630804, 121.48900536027 (社子島)

|              |                                                                                                           |
|--------------|-----------------------------------------------------------------------------------------------------------|
| 問題           | 階層式提示詞內容 (Prompt)                                                                                         |
| Q1<br>(初判)   | 這是一張航測影像，請仔細觀察其建築物主體結構、週邊道路鋪面、圍籬型態、以及地表綠化進度。請基於視覺特徵給出你的推理邏輯，並回答你認為這張影像的地點，及最精確的拍攝年份（西元）是哪一年？              |
| Q2<br>(時序比對) | 收到你的初步判斷。現在為了提升精準度，請將目前提供的同一地點的 [指定年份]「航測影像」，與我一開始提供給你的「航測影像」進行空間特徵交叉比對（比對哪些建設出現了、哪些地貌消失了）。比對完成後，請更新你的判斷。 |
| Q3<br>(圖資融合) | 收到你的初步判斷。現在為了提升精準度，請將目前提供的同一地點的 [2013 年]「數值地形圖」，與我一開始提供給你的「航測影像」進行空間特徵交叉比對。比對完成後，請更新你的判斷。                 |

## 5. 實驗結果與探討

[illegible]

實驗結果顯示以下重要趨勢：

1. 視覺特徵初判(Q1)：模型在僅面對單一張航測影像時，判斷「地點」的準確率表現尚可（特別是對於具有獨特幾何外觀的體育場或地標建物），然而對於「精確年份」之判斷能力普遍較弱，容易出現 5 至 10 年之誤差，證實了垂直視角缺乏細節脈絡的局限性。
2. 多時序交叉比對(Q2)：當 Agent 提供同地點不同年份的有標註影像後，模型的年份判斷準確度顯著提升。LLM 能夠透過視覺網路識別出兩圖之間「新建物落成」或「既有結構消失」的時間差，進行邏輯剪枝，將年份誤差縮減至 2 年以內。
3. 數值地形圖融合(Q3)：地形圖以標準化符號與文字描繪地形，提供了精確的建物輪廓線與文字路名。引入地形圖後，模型對於原先模糊的行政區與地點判斷展現了顯著的校正效果（地點 True/False 轉化為正解），補足了純影像視覺特徵的語義缺陷。

## 6. 結論與未來方向

本專題成功驗證了多模態 LLM 在地理圖資辨識上的潛力與邊界。單純的純視覺初判在年份判定上存在瓶頸，但藉由結合 LangChain 外部工具動態調用歷史圖資，並實作時序影像與數值地形圖的交叉比對提示工程，能大幅補強模型在垂直視角下的空間推理與時間定位精度。

本研究之局限性在於目前抓取之圖磚範圍（500 公尺）有時會切碎大型地標，且模型對於高度、精確坐標數值的運算仍偶有幻覺。未來研究將嘗試導入更先進之視覺區域對齊演算法，或對模型進行地理空間資訊的微調(Fine-tuning)，以期能自主實作自動化都市發展變遷之智慧偵測。

### 參考文獻

- Dorobantu, M., & others. (2026). Spatial reasoning and geometric computation bottlenecks in large language models: A comprehensive review. *Computational Linguistics Survey*, 30(1), 45–67.
- O'Sullivan, B., & others. (2024). Testing spatial concept limitations in multimodal large language models. *Journal of Spatial AI*, 14(2), 112–125.
- Zhou, L., & others. (2024). Evaluating multi-view urban scene understanding in LLMs: From street view to aerial orthophotos. *Proceedings of CVPR 2024*, 4521–4530.