

測試大型語言模型辨識地理圖資能力

孫翊維 張子修 吳欣璉 黃于哲
自然語言處理 期末專案書面報告

摘要 本研究旨在探索大型語言模型(LLM)理解與辨識航空攝影正射影像（簡稱航測影像）及數值地形圖的能力。航空攝影正射影像具備豐富的時間序列特徵，是都市變遷規劃的重要依據，但由於其垂直視角與多為公務付費資料之特性，極少被用作 LLM 的訓練數據。我們開發了一套基於 LangChain 的自動化圖資查詢平台，整合臺北市歷史圖資展示系統之 WMTS 服務，並使用 Gemini API 進行一系列對話實驗。實驗透過階層式提示詞，測試模型在單純視覺判讀、加入不同年份航測影像交叉比對，以及結合數值地形圖後，對特定地點與拍攝年份判斷的準確度提升效果。

1. 研究動機與問題

航空攝影正射影像(Orthophoto)係利用航空攝影測量技術製作，經正射糾正與坐標定位後之影像圖，其記錄了地形地貌隨時間變動的歷程，為都市發展與變遷分析之重要參據。然而，此類影像品質易受拍攝技術與天候影響，且多屬公務或付費資產，少見於公開之大型模型預訓練語料庫中。因此，精確辨識航測影像對於人類與機器皆具高度挑戰性。

本研究聚焦於以下核心問題：

- 探索多模態大型語言模型(LLM)理解垂直視角航測影像之內在機制。
- 測試 LLM 在無外部文本脈絡下，單憑視覺特徵判斷航測地點與拍攝年份之能力。
- 實驗透過工具調用(Agent)與階層式空間特徵比對，能否有效提升模型之判讀精準度。
- 評估不同性質圖資（航測影像 vs. 數值地形圖）對模型推理表現之影響。

2. 文獻回顧

近年關於 LLM 空間認知能力的研究顯示，模型在處理複雜地理圖資時仍存在限制。(O'Sullivan 等, 2024) 指出，LLM 對於距離（如「遠」與「近」）之空間概念，僅停留在靜態的字面定義，缺乏動態實際計算能力。

在視覺與城市地景判讀方面，(Zhou 等, 2025) 評估模型判讀多視角城市場景之表現，發現 LLM

在垂直視角影像（如衛星、航測影像）之表現顯著遜於街景圖，其中又以城市檢索（地點判定）之表現最為薄弱。(Dorobantu & Badea, 2026) 彙整相關研究後進一步證實，LLM 在回答空間任務時多基於訓練數據中的詞彙定義，於精確的幾何計算（如面積、距離及座標轉換）中表現欠佳。本研究以此為基礎，嘗試透過 Agent 機制與多時序圖資融合來克服上述限制。

3. 系統架構與圖資獲取

為驗證模型能力，我們實作了一套自動化圖資查詢與分析平台。

3.1 圖資來源與規格

本研究之數據源自「臺北市政府都市發展局歷史圖資展示系統」，涵蓋臺北市範圍內歷年（1945–2025 年）之航測影像及數值地形圖。系統提供符合網際網路地圖圖磚服務(WMTS)標準之介接服務。本系統設定擷取參數為：縮放層級(Zoom Level)16，比例尺約為 1:8500，每塊地圖圖磚(Tile)尺寸為 256 × 256 像素，單一圖磚涵蓋實際地表面積約 500 × 500 公尺。

3.2 圖資獲取工具設計

圖資 Agent 整合了以下核心功能模組：

- 地址解析 (Geocoding)：優先採納使用者傳入之座標；若僅輸入地名（如“台北車站”），則啟

動 geopy 套件自動查詢「臺北市 + 該地名」之精確經緯度。

2. 座標轉換：將取得之經緯度傳入 latlon_to_tile_xy 函式，換算為對應之 x 與 y 圖磚索引值。
3. 年份搜尋演算法：因特定地點並非每年皆有完整的航測影像，系統設計自動搜尋機制，動態抓取目標年份前後各三年的現存圖資，並透過網址比對後完成圖片下載。

4. 實驗方法

本研究於 Colab (Python3 CPU) 環境下實作，測試模型採用 gemini-3.1-flash-lite，並以 Gradio 建構前端對話介面進行互動實驗。

我們於臺北市內嚴格篩選了 20 處測試地點。篩選原則包括：(1) 年份落於 2000 年以後，確保航空攝影技術達到一致之解析度水準；(2) 近年地形地貌有顯著變動(如建物拆除、新建大型地標或重大公共建設)；(3) 包含具代表性之重要地標。名單如下：

- 1. 國父紀念館
- 2. 台北市政府
- 3. 南港展覽館
- 4. 達賢圖書館
- 5. 美麗華購物中心
- 6. 動物園
- 7. 華碩集團總部 (關渡)
- 8. 小巨蛋
- 9. 故宮
- 10. 政治大學自強十舍
- 11. 松山文創園區
- 12. 京華城
- 13. 臺北市北投老人服務中心
- 14. 中研院
- 15. 台北流行音樂中心
- 16. 台北車站
- 17. 臺北霞海城隍廟 (迪化街)
- 18. 捷運西門站
- 19. 25.0997583918, 121.5102736917 (北士科)
- 20. 25.1110630804, 121.48900536027 (社子島)

實驗流程採取單一對話內之多輪引導推理，具體測試提示詞(Prompts)如下表：

問題	階層式提示詞內容 (Prompt)
Q1 (初判)	這是一張航測影像，請仔細觀察其建築物主體結構、週邊道路鋪面、圍籬型態、以及地表綠化進度。請基於視覺特徵給出你的推理邏輯，並回答你認為這張影像的地點，及最精確的拍攝年份 (西元) 是哪一年？
Q2 (時序比對)	收到你的初步判斷。現在為了提升精準度，請將目前提供的同一地點的 [指定年份]「航測影像」，與我一開始提供給你的「航測影像」進行空間特徵交叉比對 (比對哪些建設出現了、哪些地貌消失了)。比對完成後，請更新你的判斷，並回答你認為這張影像的地點，及最精確的拍攝年份 (西元)是哪一年？
Q3 (圖資融合)	收到你的初步判斷。現在為了提升精準度，請將目前提供的同一地點的 [2013 年]「數值地形圖」，與我一開始提供給你的「航測影像」進行空間特徵交叉比對。比對完成後，請更新你的判斷，並回答你認為這張影像的地點，及最精確的拍攝年份 (西元)是哪一年？

表 1 本研究實作之階層式提示詞設計

5. 實驗結果與探討

透過 20 處測試地點的循序引導實驗，我們紀錄並評估模型在各階段的答題表現。

測試地點	模型初判	模型時序比對	模型圖資融合	模型初判	模型時序比對	模型圖資融合	模型初判	模型時序比對	模型圖資融合
1. 國父紀念館	2015	2017	18	1912	1912	1912	1912	1912	1912
2. 台北市政府	2012	2009	12	2001	19	2013	2012	2012	2012
3. 南港展覽館	2007	2009	2	2007	0	2004	2008	2008	2008
4. 達賢圖書館	2016	2016	1	2016	0	2016	2016	2016	2016
5. 美麗華購物中心	2002	1980	17	1980	0	1979	2000	2000	2000
6. 動物園	2006	2006	6	2002	3	1996	2002	2002	2002
7. 華碩集團總部 (關渡)	2006	2002	17	2002	17	2002	2002	2002	2002
8. 小巨蛋	2009	2011	12	2010	12	2007	2007	2007	2007
9. 故宮	2007	2015	8	2014	7	2012	2012	2012	2012
10. 政治大學自強十舍	2009	2011	12	2010	12	2007	2007	2007	2007
11. 松山文創園區	2017	2017	1	2017	0	2017	2017	2017	2017
12. 京華城	2015	2009	6	2007	8	2009	8	2009	8
13. 臺北市北投老人服務中心	2017	2022	5	2021	4	2021	4	2021	4
14. 中研院	2017	2010	11	2007	18	2002	18	2002	18
15. 台北流行音樂中心	2017	2017	0	2017	0	2017	0	2017	0
16. 台北車站	2017	2017	0	2017	0	2017	0	2017	0
17. 臺北霞海城隍廟 (迪化街)	2017	2017	0	2017	0	2017	0	2017	0
18. 捷運西門站	2017	2017	0	2017	0	2017	0	2017	0
19. 25.0997583918, 121.5102736917 (北士科)	2017	2017	0	2017	0	2017	0	2017	0
20. 25.1110630804, 121.48900536027 (社子島)	2017	2017	0	2017	0	2017	0	2017	0

圖 1 實驗資料

我們使用兩個指標評估實驗的成果:(一)地名是否正確,(二)拍攝年份是否正確，計算模型回答年份與實際年份之差距。實驗結果顯示以下重要趨勢：

5.1 各階段實驗結果

1. 視覺特徵初判(Q1)：模型在僅面對單一張航測影像時，判斷「地點」的準確率表現尚可（特別是對於具有獨特幾何外觀的體育場或地標建物），然而對於「精確年份」之判斷能力普遍較弱，容易出現 5 至 10 年之誤差，最大誤差達到 41 年，考量攝影技術的明顯差距，回答顯然不合理。

2. 多時序交叉比對(Q2)：當 Agent 提供同地點不同年份的有標註影像後，模型的地點判斷均未變動，與第一次回答相同，年份回答則有增有減。LLM 能夠透過視覺網路識別出兩圖之間「新建物落成」或「既有結構消失」的時間差。
3. 數值地形圖融合(Q3)：地形圖以標準化符號與文字描繪地形，提供了精確的建物輪廓線與文字路名；然而，引入地形圖後，模型對於原先模糊的行政區與地點判斷並未展現校正效果，推測可能是解析度問題造成模型未能獲得地形圖中的文字資訊。

5.2 實驗結果與討論

1. 地名：在 20 個地點中，LLM 正確回答了 10 個地點的名稱，並且都在第一次回答答對，而模型對於 20 個地名的回答，在三輪問答中均未改變。
2. 年份：年份回答較為浮動，在地點正確的案例中，三輪問答後與正確年份差距持續增加者有 4 組；減少者則有 3 組。

5.3 實驗結果相關發現

在實驗過程中，我們發現了以下課題：

1. 座標計算錯誤：當我們在測試輸入地名轉換座標時，系統針對在單一問題中同一地名，不同年份的圖資請求，回應了不同地點的圖資。
2. 圖資內容幻覺：為了測試 LLM 是否可「看見」圖片內容，我們詢問模型圖片內容，回應內容包括了位於該地區，但不在圖片內的地標建物。

6. 結論與未來方向

本報告驗證了多模態 LLM 在地理圖資辨識上的潛力與邊界，結合 LangChain 外部工具動態調用歷史圖資，並實作時序影像與數值地形圖的交叉比對提示工程。研究結果證實了現階段 LLM 在垂直視角缺乏細節脈絡的局限性，以及回答空間、地理等問題時，以模型內部知識回答，而非實際空間推理的幻覺問題。

本研究之局限性在於目前抓取之圖磚範圍(500 公尺)有時會切碎大型地標，且模型對於高度、精確坐標數值的運算仍偶有幻覺；而外部圖資的導入對於模型回應的改善未如預期，可能肇因為圖片解析度以及涵蓋範圍不足等問題。未來研究可朝向對於外部圖資進行圖塊拼接等

處理後，測試檢索增強生成(Retrieval-Augmented Generation, RAG)方式測試，或對模型進行地理空間資訊的微調(Fine-tuning)，以期能自主實作自動化都市發展變遷之智慧偵測。

參考文獻

- Dorobantu, G., & Badea, A. (2026). Geospatial reasoning and awareness in large language models: a systematic review. *Artificial Intelligence Review*, 59. <https://doi.org/10.1007/s10462-026-11512-x>
- O'Sullivan, K., Schneider, N. R., & Samet, H. (2024). Metric Reasoning in Large Language Models. *Proceedings of the 32nd ACM International Conference on Advances in Geographic Information Systems (SIGSPATIAL '24)*, 501–504. <https://doi.org/10.1145/3678717.3691226>
- Zhou, B., Yang, H., Chen, D., Ye, J., Bai, T., Yu, J., Songyang, Z., Lin, D., He, C., & Li, W. (2025). UrBench: A Comprehensive Benchmark for Evaluating Large Multimodal Models in Multi-View Urban Scenarios. *Proceedings of the AAAI Conference on Artificial Intelligence*, 39, 10707–10715. <https://doi.org/10.1609/aaai.v39i10.33163>