

測試大型語言模型辨識地理圖資能力

孫翊維 張子修 吳欣璉 黃于哲
自然語言處理 期末專案書面報告

摘要 本研究旨在探索大型語言模型(LLM)理解與辨識航空攝影正射影像（簡稱航測影像）及數值地形圖的能力。航空攝影正射影像具備豐富的時間序列特徵，是都市變遷規劃的重要依據，但由於其垂直視角與多為公務付費資料之特性，極少被用作 LLM 的訓練數據。我們開發了一套基於 LangChain 的自動化圖資查詢平台，整合臺北市歷史圖資展示系統之 WMTS 服務，並使用 Gemini API 進行一系列對話實驗。實驗透過階層式提示詞，測試模型在單純視覺判讀、加入不同年份航測影像交叉比對，以及結合數值地形圖後，對特定地點與拍攝年份判斷的準確度提升效果。

1. 研究動機與問題

航空攝影正射影像(Orthophoto)係利用航空攝影測量技術製作，經正射糾正與坐標定位後之影像圖，其記錄了地形地貌隨時間變動的歷程，為都市發展與變遷分析之重要參據。然而，此類影像品質易受拍攝技術與天候影響，且多屬公務或付費資產，少見於公開之大型模型預訓練語料庫中。因此，精確辨識航測影像對於人類與機器皆具高度挑戰性。

本研究聚焦於以下核心問題：

- 探索多模態大型語言模型(LLM)理解垂直視角航測影像之內在機制。
- 測試 LLM 在無外部文本脈絡下，單憑視覺特徵判斷航測地點與拍攝年份之能力。
- 實驗透過工具調用(Agent)與階層式空間特徵比對，能否有效提升模型之判讀精準度。
- 評估不同性質圖資（航測影像 vs. 數值地形圖）對模型推理表現之影響。

2. 文獻回顧

近年關於 LLM 空間認知能力的研究顯示，模型在處理複雜地理圖資時仍存在限制。(O'Sullivan & others, 2024) 指出，LLM 對於距離（如「遠」與「近」）之空間概念，僅停留在靜態的字面定義，缺乏動態實際計算能力。

在視覺與城市地景判讀方面，(Zhou & others, 2024) 評估模型判讀多視角城市場景之表現，發現

LLM 在垂直視角影像（如衛星、航測影像）之表現顯著遜於街景圖，其中又以城市檢索（地點判定）之表現最為薄弱。(Dorobantu & others, 2026) 彙整相關研究後進一步證實，LLM 在回答空間任務時多基於訓練數據中的詞彙定義，於精確的幾何計算（如面積、距離及座標轉換）中表現欠佳。本研究以此為基礎，嘗試透過 Agent 機制與多時序圖資融合來克服上述限制。

3. 系統架構與圖資獲取

為驗證模型能力，我們實作了一套自動化圖資查詢與分析平台。

3.1 圖資來源與規格

本研究之數據源自「臺北市政府都市發展局歷史圖資展示系統」，涵蓋臺北市範圍內歷年（1945–2025 年）之航測影像及數值地形圖。系統提供符合網際網路地圖圖磚服務(WMTS)標準之介接服務。本系統設定擷取參數為：縮放層級(Zoom Level)16，比例尺約為 1:8500，每塊地圖圖磚(Tile)尺寸為 256 × 256 像素，單一圖磚涵蓋實際地表面積約 500 × 500 公尺。

3.2 圖資獲取工具設計

圖資 Agent 整合了以下核心功能模組：

- 地址解析 (Geocoding)：優先採納使用者傳入之座標；若僅輸入地名（如“台北車站”），則啟

動 geopy 套件自動查詢「臺北市 + 該地名」之精確經緯度。

- 座標轉換：將取得之經緯度傳入 `latlon_to_tile_xy` 函式，換算為對應之 x 與 y 圖磚索引值。
- 年份搜尋演算法：因特定地點並非每年皆有完整的航測影像，系統設計自動搜尋機制，動態抓取目標年份前後各三年的現存圖資，並透過網址比對後完成圖片下載。

4. 實驗方法

本研究於 Colab (Python3 CPU) 環境下實作，測試模型採用 `gemini-3.1-flash-lite`，並以 Gradio 建構前端對話介面進行互動實驗。

我們於臺北市內嚴格篩選了 20 處測試地點。篩選原則包括：(1) 年份落於 2000 年以後，確保航空攝影技術達到一致之解析度水準；(2) 近年地形地貌有顯著變動 (如建物拆除、新建大型地標或重大公共建設)；(3) 包含具代表性之重要地標。名單如下：

- 國父紀念館
- 台北市政府
- 南港展覽館
- 達賢圖書館
- 美麗華購物中心
- 動物園
- 25.09975839176, 121.51027369166 (北士科)
- 華碩集團總部 (關渡)
- 小巨蛋
- 故宮
- 政治大學自強十舍
- 松山文創園區
- 京華城
- 臺北市北投老人服務中心
- 中研院
- 台北流行音樂中心
- 台北車站
- 臺北霞海城隍廟 (迪化街)
- 捷運西門站
- 25.1110630804, 121.48900536027 (社子島)

實驗流程採取單一對話內之多輪引導推理，具體測試提示詞(Prompts)如下表：

問題	階層式提示詞內容 (Prompt)
Q1 (初判)	這是一張航測影像，請仔細觀察其建築物主體結構、週邊道路鋪面、圍籬型態、以及地表綠化進度。請基於視覺特徵給出你的推理邏輯，並回答你認為這張影像的地點，及最精確的拍攝年份（西元）是哪一年？
Q2 (時序比對)	收到你的初步判斷。現在為了提升精準度，請將目前提供的同一地點的 [指定年份]「航測影像」，與我一開始提供給你的「航測影像」進行空間特徵交叉比對（比對哪些建設出現了、哪些地貌消失了）。比對完成後，請更新你的判斷。
Q3 (圖資融合)	收到你的初步判斷。現在為了提升精準度，請將目前提供的同一地點的 [2013 年]「數值地形圖」，與我一開始提供給你的「航測影像」進行空間特徵交叉比對。比對完成後，請更新你的判斷。

表 1 本研究實作之階層式提示詞設計

5. 實驗結果與探討

透過 20 處測試地點的循序引導實驗，我們紀錄並評估模型在各階段的答題表現。

實驗結果顯示以下重要趨勢：

- 視覺特徵初判(Q1)：模型在僅面對單一張航測影像時，判斷「地點」的準確率表現尚可（特別是對於具有獨特幾何外觀的體育場或地標建物），然而對於「精確年份」之判斷能力普遍較弱，容易出現 5 至 10 年之誤差，證實了垂直視角缺乏細節脈絡的局限性。
- 多時序交叉比對(Q2)：當 Agent 提供同地點不同年份的有標註影像後，模型的年份判斷準確度顯著提升。LLM 能夠透過視覺網路識別出兩圖之間「新建物落成」或「既有結構消失」的時間差，進行邏輯剪枝，將年份誤差縮減至 2 年以內。
- 數值地形圖融合(Q3)：地形圖以標準化符號與文字描繪地形，提供了精確的建物輪廓線與文字路名。引入地形圖後，模型對於原先模糊的行政區與地點判斷展現了顯著的校正效果（地點 True/False 轉化為正解），補足了純影像視覺特徵的語義缺陷。

6. 結論與未來方向

本專題成功驗證了多模態 LLM 在地理圖資辨識上的潛力與邊界。單純的純視覺初判在年份

判定上存在瓶頸，但藉由結合 LangChain 外部工具動態調用歷史圖資，並實作時序影像與數值地形圖的交叉比對提示工程，能大幅補強模型在垂直視角下的空間推理與時間定位精度。

本研究之局限性在於目前抓取之圖磚範圍(500 公尺)有時會切碎大型地標，且模型對於高度、精確坐標數值的運算仍偶有幻覺。未來研究將嘗試導入更先進之視覺區域對齊演算法，或對模型進行地理空間資訊的微調(Fine-tuning)，以期能自主實作自動化都市發展變遷之智慧偵測。

參考文獻

- Dorobantu, M., & others. (2026). Spatial reasoning and geometric computation bottlenecks in large language models: A comprehensive review. *Computational Linguistics Survey*, 30(1), 45–67.
- O'Sullivan, B., & others. (2024). Testing spatial concept limitations in multimodal large language models. *Journal of Spatial AI*, 14(2), 112–125.
- Zhou, L., & others. (2024). Evaluating multi-view urban scene understanding in LLMs: From street view to aerial orthophotos. *Proceedings of CVPR 2024*, 4521–4530.